

作业4：电影评论情感分类实验报告（改进版）

姓名：庄仕豪

学号：23336355

一、实验任务与要求

本实验使用 IMDB 电影评论数据集完成二分类任务（positive/negative），并对以下模型进行对比：

1. TF-IDF + Logistic Regression
2. TF-IDF + Linear SVM
3. RNN

二、数据集与预处理

2.1 数据来源

数据集为 Hugging Face 平台 IMDB 数据集，脚本首次运行自动下载并缓存到 data 目录。

数据规模如下：

1. 训练集：25000 条
2. 测试集：25000 条
3. 标签：0（负样本）、1（正样本）

2.2 预处理流程

1. 全部文本转小写
2. 去除非字母数字字符
3. 空格分词

对于 TF-IDF 模型：

1. 采用 unigram + bigram（1-gram, 2-gram）
2. 使用英文停用词过滤
3. 词特征上限设置为 30000

对于 RNN 模型：

1. 在训练集上构建词表（max vocab 60000 起）
2. 句子截断/补齐到固定长度（max len 220 起）
3. 加入、特殊符号

三、模型方法与改进策略

3.1 TF-IDF + Logistic Regression

经典文本分类基线。该方法在高维稀疏空间中训练稳定、速度快，对情感任务通常有较强表现。

3.2 TF-IDF + Linear SVM

将线性分类器替换为 LinearSVC。SVM 对稀疏特征表现稳定，是文本分类常见强基线。

3.3 RNN (BiLSTM) 改进

与普通 RNN 相比，本次进行了系统增强：

1. 从单向 LSTM 改为双向 BiLSTM
2. 隐层增大 (hidden dim 256)、多层结构 (2 layers)
3. 使用 dropout 抑制过拟合
4. 增加梯度裁剪 (gradient clipping)
5. 引入验证集 (训练集 9:1 划分)
6. 使用 ReduceLROnPlateau 学习率调度
7. 采用 early stopping (patience)

四、评估指标

为避免只看 Accuracy 带来的片面性，本实验使用以下指标：

1. Accuracy: 整体正确率
2. Precision: 正类预测的准确性
3. Recall: 正类召回能力
4. F1: Precision 与 Recall 的调和平均
5. ROC-AUC: 概率排序能力，越接近 1 越好

其中：

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$

五、实验设置与运行

环境：conda activate pytorch

核心运行命令：

```
cd 作业4\code
conda activate pytorch
python .\sentiment_classification.py --data_dir ..\data --result_dir ..\result --
subset_size -1 --rnn_epochs 6 --batch_size 128 --max_len 220 --max_vocab 60000 --
rnn_lr 0.001 --patience 2
```


说明：subset_size=-1 表示使用完整 25000 训练集与完整 25000 测试集。

六、实验结果


来自 [./result/performance.csv](#) 的实测结果如下：

Model	Accuracy	Precision	Recall	F1	ROC_AUC
TF-IDF + LogisticRegression	0.8832	0.8820	0.8849	0.8834	0.9526
TF-IDF + LinearSVM	0.8729	0.8810	0.8622	0.8715	0.9467
RNN (BiLSTM, PyTorch)	0.8281	0.8081	0.8605	0.8335	0.8985
RNN-Strong (BiLSTM)	0.8374	0.8561	0.8112	0.8330	0.9063

6.1 指标总览图




6.2 RNN 训练过程曲线




6.3 混淆矩阵


TF-IDF + LogisticRegression :




TF-IDF + LinearSVM:



RNN (BiLSTM, PyTorch):



RNN-Strong (BiLSTM):



七、结果分析

7.1 综合性能对比

1. LogisticRegression 在五项指标上整体最优 (F1=0.8834)
2. LinearSVM 紧随其后 (F1=0.8715)
3. 改进后的 BiLSTM 相比早期版本显著提升, 但仍略低于 TF-IDF 线性模型

说明在 IMDB 任务中, 经过良好特征工程的线性模型依然是非常强的基线。

7.2 RNN 效果

1. 与简单的RNN相比, 改进版 RNN 已从接近随机水平提升到 F1 0.83+ 区间
2. 二阶段更高参数训练提高了 Accuracy 与 ROC-AUC, 但 F1 与第一阶段接近
3. 这表明模型存在一定的阈值/偏置变化, 继续提升可能需要更系统的结构升级而非仅增加训练轮数

7.3 为什么 RNN 仍未超过 TF-IDF 线性模型

可能原因包括:

1. 未使用预训练词向量或预训练语言模型
2. 纯 BiLSTM 对长文本关键句提取能力有限
3. 文本分类任务中, 情感关键词对线性模型已足够友好

八、结论与后续优化方向

8.1 结论

本次实验在完整 IMDB 数据上完成了三类模型与多指标评估, 结果显示:

1. 当前最佳模型为 TF-IDF + Logistic Regression
2. SVM 表现稳定且接近 LR
3. 改进后 BiLSTM 已明显提升, 但仍未超过 TF-IDF 线性基线

8.2 后续优化方向

1. 尝试 GRU + Attention 或 TextCNN-LSTM 混合结构
2. 使用 GloVe/FastText 预训练词向量
3. 尝试 BERT 类预训练模型进行对照
4. 在验证集上搜索最佳分类阈值以提升 F1

九、实验产出文件

1. 代码主文件: [../code/sentiment_classification.py](#)
2. 指标结果: [../result/performance.csv](#)
3. 指标图: [../result/accuracy_comparison.png](#)
4. 训练曲线: [../result/rnn_training_curve.png](#)

5. 混淆矩

阵: [../result/confusion_matrix_tf_idf_logisticregression.png](#)、[../result/confusion_matrix_tf_idf_linearsvm.png](#)、[../result/confusion_matrix_rnn_bilstm_pytorch.png](#)、[../result/confusion_matrix_rnn_strong_bilstm.png](#)