

多模态最终报告 文档理解 + 多模态检索问答系统

小组成员 1: 庄仕豪 学号: 23336355

小组成员 2: 钟晨晖 学号: 23336336

摘要

本文提出并实现了一套面向复杂版面 PDF 文档的多模态检索增强生成 (Multimodal RAG) 系统 MultimodalQA。系统以 IBM Docling 完成 PDF 版面分析与结构化抽取 (文本块 / 表格 Markdown / 图像裁剪), 以智谱 GLM-4.6V 生成图表语义摘要, 以 BAAI/BGE-M3 构建 1024 维稠密向量索引 (ChromaDB 持久化), 并通过 Multi-Vector Retriever 实现“摘要召回、原图回传”的代理检索策略, 最终由 GLM-4.6V 生成带页码与图号引用的多模态答案。

为定量评估系统优势, 本文构建了一个包含 **200 道题目、5 篇文档、4 类领域、3 档难度** 的自建 QA 数据集, 设计三路基线对比: 多模态 RAG (完整系统)、纯文本保守基线 (无图、无证据则拒答)、纯文本开放基线 (无图、允许基于上下文推断), 以 ANLS 与准确率为指标进行评测。实验结果表明, 在必须依赖图表视觉信息的题目上 (100 道), 多模态 RAG 的准确率 (65%) 显著高于纯文本保守基线 (18%) 和纯文本开放基线 (42%), 提升分别为 +47 个百分点 (pp) 和 +23 pp (McNemar 检验 $p < 0.0001$), 而在纯文本题目上三路无显著差异, 验证了多模态架构的必要性与针对性。

系统已实现完整的 Web 前后端 (Vue 3 + FastAPI), 支持 PDF 拖拽上传、实时进度推送 (SSE)、LaTeX 公式渲染与引用溯源。

目录

一、 引言	3
二、 相关工作	3
(一) 检索增强生成 (RAG)	3
(二) 文档视觉理解	3
(三) 多模态 RAG	4
(四) 文档解析工具	4
三、 方法	4
(一) 阶段一: 文档摄取与结构化解析	4
(二) 阶段二: 离线索引构建	5
1. VLM 摘要生成	5
2. BGE-M3 向量化	5

3. 代理召回策略	5
(三) 阶段三: 混合召回	5
(四) 阶段四: 溯源生成	5
四、 实验	6
(一) 实验设置	6
1. 系统配置	6
2. 评测数据集	6
3. 评测指标	7
4. 三路基线设计	7
(二) 实验结果	8
1. 总体性能对比	8
2. 按题型细分	8
3. 按难度分析	9
4. 视觉题 vs 非视觉题	9
5. 统计显著性检验	9
6. 延迟分析	10
7. 可视化分析	10
8. 错误分析	11
五、 结论	13
六、 局限性与未来工作	13

一、引言

随着企业与科研场景中非结构化文档的爆炸式增长，如何从包含复杂排版的 PDF（多栏布局、嵌套表格、统计图表、数学公式）中准确检索并回答自然语言问题，成为文档智能领域的核心挑战。

传统 RAG（Retrieval-Augmented Generation）系统^[1] 在处理纯文本文档时已取得良好效果，但面对图表、混淆矩阵、训练曲线等视觉信息时力不从心——文本化的图说或摘要往往丢失关键的颜色、趋势和精确读数信息，导致模型产生模糊甚至错误的判断。

本文的核心贡献包括：

1. **完整多模态 RAG 管道**：从 PDF 解析、VLM 摘要生成、向量化检索到多模态答案生成的端到端系统，提出“摘要入库、原图回传”的代理召回策略，在不显著增加索引体积的前提下支持图像级问答。
2. **三路消融对比设计**：新增“纯文本开放基线”（无图、允许推断），区分多模态提升来源于“视觉理解”还是“保守基线（无证据则拒答）的过度拒答”，使对比实验更加公平。
3. **多领域双语自建 QA 数据集**：5 篇 PDF 文档，覆盖 4 类领域（个人 ML 实验报告、NLP 学术论文、气候科学报告、宏观经济报告）、200 道题目、3 档难度。其中 2 篇为英文文档（Infini-Attention 论文、IPCC AR6 报告），其余 3 篇为中文文档，所有题目均以中文提问，兼顾了跨语言检索与问答能力的评测。
4. **完整 Web 演示系统**：前后端分离，支持实时进度、前端 LaTeX 渲染、引用溯源弹窗等工程特性。

二、相关工作

（一）检索增强生成（RAG）

Lewis 等人^[1] 提出将稠密检索与序列到序列生成结合的 RAG 框架，将开放域问答的知识存储从参数化记忆转移至可更新的外部文档库，极大提升了模型对长尾知识的覆盖能力。后续工作（如 Self-RAG^[2]、HyDE 等）进一步优化了检索质量与生成的忠实性。

（二）文档视觉理解

DocVQA^[3]、ChartQA^[4] 等数据集揭示了视觉文档理解的独特难点：仅凭 OCR 文本无法回答需要视觉推理的问题（如图表趋势、表格布局）。ColPali^[5] 提出直接以页面图像向量化进行检索，完全绕开文本提取环节；但在精确数值读取上仍有局限。

（三）多模态 RAG

M3DocRAG^[6] 在多文档场景下引入多向量检索与多模态生成；VisRAG^[7] 通过实验证明保留视觉信息对 RAG 的重要性。本文参考上述架构，结合国内可用的 API（智谱 GLM-4.6V）设计了适合中英文混合文档的系统。

（四）文档解析工具

IBM Docling^[8] 提供基于深度学习的 PDF 版面分析，能够高精度分离文本、表格和图像区域，并将表格转为结构化 Markdown，为后续的语义分块和向量化奠定基础。

三、方法

本系统由四个阶段组成，如图 1 所示。




图 1: MultimodalQA 四阶段处理流程

（一）阶段一：文档摄取与结构化解析

输入 PDF 经 IBM Docling（GPU 加速）进行版面分析，输出三类结构化元素：

- 文本块（TEXT）：正文段落、标题、公式，保留标题层级上下文；
- 表格（TABLE）：以 Markdown 格式保留行列结构；
- 图像（FIGURE）：裁剪为独立图片文件，保留页码与标签；
- 页面图（PAGE_IMAGE）：全页渲染，用于引用溯源弹窗。

文本块经过合并小块（min=80 字符）与滑动窗口切分（max=1500, overlap=200）后形成检索单元。

（二）阶段二：离线索引构建

1、VLM 摘要生成

对每个 FIGURE 和 TABLE 元素，调用 GLM-4.6V 生成 100-200 字的语义摘要，作为该视觉元素的文本代理（proxy）存入向量库。摘要描述图表类型、关键数值、趋势与结论，使得纯文本检索模型也能通过语义相似度命中视觉内容。

2、BGE-M3 向量化

使用 BAAI/BGE-M3^[9] 对所有文本块及视觉摘要生成 1024 维稠密向量，以 FP16 精度在 CUDA 设备上完成批量编码（batch=8，max_length=8192）。向量与元数据（页码、类型、标签、图片路径）一同持久化至 ChromaDB。

3、代理召回策略

索引存储的是摘要文本的向量，但元数据中记录了原始图片路径。检索命中摘要后，系统取出 image_path 并将原始图片附加到 VLM Prompt 中，实现”以文本精度检索、以图像质量回答”，兼顾了检索效率（索引体积小）与回答质量（完整视觉信息）。

（三）阶段三：混合召回

用户问题同样经 BGE-M3 编码后，在 ChromaDB 中进行余弦相似度检索（top-k=5，阈值=0.3），返回文本块、表格摘要和图像摘要三类候选。对命中图像摘要的结果，系统进一步加载对应原始图片，组成图文混合的上下文包（context pack）。

（四）阶段四：溯源生成

系统支持三种生成模式：

- **auto**（多模态）：有图像时将原图与文本上下文一并传入 GLM-4.6V，启用多模态推理；
- **grounded**（诚实基线）：仅使用文本上下文，无足够证据时明确拒答；
- **open**（公平基线）：仅使用文本上下文，允许基于间接上下文进行合理推断。

GLM-4.6V 按 system prompt 要求在回答末尾附加结构化引用标签：

```
<citation page="5" type="figure" label="Figure 1"/>
```

前端解析该标签，渲染为可点击的”第 5 页”按钮，点击弹窗显示对应页面原图。

四、实验

（一）实验设置

1、系统配置

表 1: 系统核心配置

组件	配置
文档解析	IBM Docling 2.95 (GPU 加速, CUDA 12.4)
嵌入模型	BAAI/BGE-M3, 1024 维, FP16, CUDA
向量库	ChromaDB (余弦相似度, 持久化)
VLM	智谱 GLM-4.6V (max_tokens=4096, temperature=0.1)
检索参数	top-k=5, score_threshold=0.3, max_images=3
运行环境	Windows 11, RTX 4070/4060 Laptop GPU (8GB), Python 3.10

2、评测数据集

本文构建了一个多领域双语自建 QA 数据集 (表 2), 共 200 道题目, 涵盖 5 篇 PDF (3 篇中文文档、2 篇英文文档)、4 类领域、3 种题型、3 档难度。所有题目均以中文提问, 兼顾了中英双语文档的跨语言检索与问答。

题型上, 本文将题目分为两大类:

- **视觉题** (requires_visual=true, 共 100 道): 必须依赖图表的视觉信息才能正确回答, 包含两种子类型: (a) **仅靠图片才能回答**——如混淆矩阵单元格读数、训练曲线趋势判断, 文本摘要中不包含这些数值; (b) **图片有明显帮助**——如颜色读取、图表比较、多图对比, 文字描述存在但远不如直接看图准确。
- **非视觉题** (共 100 道): 仅凭文本或表格内容即可作答, 无需图像, 如精确数值读取、段落理解等。

视觉题与非视觉题的划分是本实验消融设计的核心依据: 在非视觉题上, 三种基线模式理论上能力相当; 在视觉题上, 多模态系统因能直接读取原始图片而具有明显优势。

表 2: 评测数据集构成

文档	领域	题数	视觉题
K-Means/GMM 实验报告	ML 实验	40	17
IMDB 情感分类报告	ML 实验	40	19
Infini-Attention 论文 (arXiv)	CS / NLP	32	12
IPCC AR6 综合报告摘要	气候/环境	44	20
IMF 战略经济前景报告	宏观经济	34	22
合计	5 篇 (4 类)	200	100 (50%)

题型分布: figure (图表类) 100 道, table (表格数值) 55 道, text (文本理解) 45 道。难度

分布：easy 101 道，medium 77 道，hard 22 道。

3、评测指标

本文使用两个互补指标：

- **ANLS**（Average Normalized Levenshtein Similarity，平均归一化编辑距离相似度）

ANLS 是 DocVQA^[3] 提出的文档问答标准指标，专为应对”回答措辞与标准答案不同但语义正确”的场景设计。计算分三步：

1. **NLS**（单题单答案相似度）：

$$\text{NLS}(\hat{a}, a) = 1 - \frac{\text{EditDistance}(\hat{a}, a)}{\max(|\hat{a}|, |a|)}$$

完全一致得 1.0，完全不同得 0.0。

2. **阈值截断**（ $\tau = 0.5$ ）：若一道题有多个等价标准答案，取其中与预测相似度最高的 NLS；若该最大 $\text{NLS} < 0.5$ ，则本题得分归零（表示”差距过大，视为答错”）；否则保留 NLS 值。

3. **ANLS = 全部题目得分的算术平均值。**

扩展处理：标准 NLS 仅做字符级编辑距离，对文档 QA 中常见的以下情形会误判为”错”，因此本文在计算 NLS 前额外增加三条预处理规则（按优先级顺序）：

1. **子串包含：**若标准答案作为子串出现在模型回答中，直接给满分。

例：标准答案为 0.5937，模型回答”Random 初始化的测试集准确率为 0.5937”，编辑距离很大，但答案已包含在内，判为正确。

2. **数值格式归一化：**百分数与小数视为等价。

例：标准答案为 59.37%，模型回答 0.5937，自动转换后判为正确。

3. **有序比较：**标准答案形如 $A > B$ 时，只要模型回答中 A、B 按顺序出现即判为正确。

例：标准答案为 *Full > Spherical*，模型答”Full 协方差性能最优，其次是 *Spherical*”，判为正确。

- **准确率（Accuracy）：**以单题 $\text{NLS} \geq 0.5$ 作为”答对”的判定标准，统计答对题数占总题数的比例。相比 ANLS 均值，准确率更直观，便于按题型、难度、视觉/非视觉等维度进行分组对比。

4、三路基线设计

表 3: 三路基线对比设计

模式	检索内容	角色
多模态 RAG	文本 + 表格摘要 + 原始图片	完整系统
纯文本保守基线	文本 + 表格摘要，无图	无视觉证据则明确拒答
纯文本开放基线	文本 + 表格摘要，无图	允许基于上下文合理推断

新增纯文本开放基线的动机：若多模态系统优势仅来自保守基线的”过度拒答”而非真实视觉理解，则开放基线的分数应接近多模态系统。若开放基线仍显著低于多模态系统，则可确认优势来自视觉信息。

（二）实验结果

1、总体性能对比

表 4: 三路基线总体性能对比（200 题）

模式	ANLS	Accuracy 准确率
多模态 RAG	0.6950	69.50%
纯文本保守基线	0.4500	45.00%
纯文本开放基线	0.5850	58.50%
多模态 vs 保守基线（提升）	+0.2450	+24.5 pp
多模态 vs 开放基线（提升）	+0.1100	+11.0 pp

多模态 RAG 在整体准确率上达到 69.5%，比保守基线（45.0%）高出 24.5 个百分点，比允许推断的开放基线（58.5%）高出 11.0 个百分点。开放基线相比保守基线提升了 13.5 pp，说明在没有图片的情况下允许模型推断确实有助于提高准确率，但仍不及多模态系统，证明差距的主要来源是视觉信息而非基线设计缺陷。

2、按题型细分

表 5: 按题型分类的准确率对比

题型	数量	多模态	纯文本保守	纯文本开放
figure（视觉图表）	100	65%	18%	42%
table（表格数值）	55	73%	71%	75%
text（文本理解）	45	76%	73%	76%

题型分析揭示了三个规律：（1）**figure 类差距最显著**：多模态（65%）vs 保守基线（18%），差距达 47 pp。保守基线在图表题上的 18% 准确率中，绝大多数（85%）来自拒答，说明纯文本系统几乎无法回答需要读图的问题。（2）**table 和 text 类三路基本持平**：多模态与两个纯文本基线的差距均在 5 pp 以内，说明多模态架构在处理结构化文本和表格时不引入额外噪声，与纯文本系统等效。值得注意的是开放基线在 table 题上（75%）略高于多模态（73%），这是因为表格以 Markdown 文本形式存入索引，纯文本系统也能直接读取精确数值，而多模态系统有时会将图片和表格混淆召回，引入轻微干扰。（3）**结论**：多模态架构的优势高度集中于视觉信息密集的题目，对纯文本推理能力无负面影响，体现了”按需使用视觉”的设计合理性。

3、按难度分析

表 6: 按难度分类的准确率对比

难度	数量	多模态	纯文本保守	纯文本开放
easy (简单)	101	76%	64%	70%
medium (中等)	77	62%	30%	49%
hard (困难)	22	64%	9%	36%

难度梯度分析表明，多模态优势随题目难度增大而扩大：easy 题多模态领先保守基线 12 pp，medium 题扩大至 32 pp，hard 题达到 55 pp。hard 题中保守基线准确率仅 9%（22 题中答对 2 题），说明这类需要跨图比较或多步推理的题目对纯文本系统几乎无解，而多模态系统能借助原始图像完成更复杂的视觉推理，准确率维持在 64%。多模态系统自身在 medium 题（62%）略低于 easy 题（76%），主要因为 medium 题更多涉及趋势判断和区域比较，对 VLM 的图表理解能力要求更高。

4、视觉题 vs 非视觉题

表 7: 视觉题与非视觉题准确率对比

子集	数量	多模态	纯文本保守	纯文本开放
视觉题	100	65%	18%	42%
非视觉题	100	74%	72%	75%

视觉/非视觉对比是本实验设计的核心消融维度。在非视觉题上，三路基线差距极小（多模态 74%、保守 72%、开放 75%），McNemar 检验 $p = 0.683$ ，差异统计上不显著，证明多模态系统在不需要图像的题目上与纯文本系统完全等效——即视觉模块不会干扰文本推理。在视觉题上，多模态（65%）vs 保守基线（18%）差距为 47 pp，McNemar 检验 $\chi^2 = 43.18$ ， $p < 0.0001$ ，高度显著。两个子集结论形成鲜明对比，精确定位了多模态架构发挥作用的边界：凡是需要图表信息的题目，视觉模块带来显著提升；凡是不需要图表的题目，视觉模块不产生额外代价。

5、统计显著性检验

对多模态 RAG 与纯文本保守基线在相同题目上的配对二分类结果，应用 McNemar 检验（适用于配对样本的 2×2 列联表）。

检验统计量：

$$\chi^2 = \frac{(b - c)^2}{b + c} \quad (1)$$

其中 b 为”多模态对、纯文本错”的题数， c 为”多模态错、纯文本对”的题数。

表 8: McNemar 检验结果（多模态 vs 纯文本保守基线）

子集	b (多模态对、保守错)	c (多模态错、保守对)	χ^2	p
全部 (n=200)	52	3	41.89	< 0.0001 (显著)
视觉题 (n=100)	48	1	43.18	< 0.0001 (显著)
非视觉题 (n=100)	4	2	0.17	0.683 (不显著)

在视觉题子集中, $b = 48$ (多模态答对但保守基线答错) 远大于 $c = 1$ (反之), 不对称性极强, $\chi^2 = 43.18$, $p < 0.0001$, 差异高度显著。在非视觉题子集中, $b = 4$, $c = 2$, $p = 0.683$, 不显著, 与上节结论吻合: 两个系统在不依赖图像的题目的能力相当。这一检验排除了”随机波动”对结论的威胁, 证明多模态系统的优势具有统计可信性。

6、延迟分析

表 9: 平均每题推理延迟

模式	平均延迟 (秒/题)
多模态 RAG	5.0
纯文本保守基线	3.7
纯文本开放基线	9.8
图像附加开销 (多模态 - 保守基线)	+1.4
平均每题图片数	1.42

多模态 RAG 平均每题耗时 5.0 秒, 相比保守基线 (3.7 秒) 仅多出 1.4 秒, 折算为每张图约 1.0 秒的额外开销 (平均 1.42 张/题), 代价极小。值得注意的是开放基线 (9.8 秒) 延迟反而最高, 接近多模态的两倍, 原因在于”允许推断”的 prompt 引导模型生成更长的推理链, 说明延迟瓶颈在于 LLM 生成长度而非图像传输。综合来看, 多模态模式在仅增加 28% 延迟 (1.4/5.0) 的前提下, 将视觉题准确率从 18% 提升至 65%, 性价比显著。

7、可视化分析

图 2 展示了三路基线在各题型上的准确率对比, 可直观看到 figure 类的大幅差距与 table/text 类的基本持平。图 3 聚焦视觉/非视觉分组, 清晰呈现多模态优势的集中区间。图 4 为每道题的 ANLS 得分 heatmap, 纵向比较三路基线在每道题上的表现, 深色区域 (得分低) 集中在视觉类题目的保守基线行, 与量化结论吻合。




图 2: 三路基线按题型准确率对比。figure 类差距达 47 pp, table/text 类三路基本持平。




图 3: 视觉题（左）vs 非视觉题（右）三路准确率对比。视觉题差距高度显著 ($p < 0.0001$), 非视觉题无显著差异 ($p = 0.683$)。



图 4: 每道题 ANLS 得分 heatmap (行: 三种模式, 列: 题号)。深色区域集中于视觉类题目的保守基线行。

8、错误分析

多模态 RAG 共答错 61 道题（准确率 69.5%），对失败案例按题型和原因进行分类，结果如表 10 和图 5 所示。

表 10: 多模态 RAG 失败案例分布

类别	失败数	占全部失败	该类型失败率
figure 题失败	35	57%	35% (35/100)
table 题失败	15	25%	27% (15/55)
text 题失败	11	18%	24% (11/45)
<i>figure 细分:</i>			
图像未召回 (检索失败)	5	8%	14% (5/35 figure 失败)
图像已召回但仍答错 (VLM 误判)	30	49%	86% (30/35 figure 失败)




图 5: 纯文本保守基线在视觉题上的失败原因分布。82 道答错题中 85% 为拒答，15% 为答错。

综合分析，多模态 RAG 的失败案例可归纳为以下四类：

- VLM 视觉理解误判（最主要，约 49% 的失败）：**图像已被正确召回并发送给 GLM-4.6V，但 VLM 对图表的读数或趋势判断出现偏差。典型场景包括：折线图趋势方向判断错误（混淆”上升”与”下降”）、柱状图数值读取精度不足（对近似值的估读存在偏差）、多子图对比时注意力分散（如 4 张混淆矩阵需同时比较）。这是当前系统最主要的失败来源，根本限制在于 VLM 的图表理解能力上限。
- 图像检索失败（约 8% 的失败，即 5 道）：**相关图表未被 top-5 召回，系统在没有视觉信息的情况下降级为纯文本推理，导致答错。主要发生在长文档（IPCC 报告、英文论文）中图表标题与问题措辞差异较大的情况下。
- 跨语言答案匹配偏差（约 8%）：**2 篇英文文档的题目以中文提问，模型有时混合中英文回答，导致即使语义正确、ANLS 也因字符串差异被低估而判为答错。例如模型答”K-Means++”而 gold 为”KMeans++”，编辑距离非零但语义等价。
- 标准答案粒度不匹配（约 18% 的 table/text 失败）：**对于需要回答区间或趋势描述的题目（如”约 50 60 cm”），模型给出的具体数值（”约 75cm”）与标准答案粒度不同，ANLS 判为答错但实际语义可能是合理的。这类问题的改进方向是完善 gold 答案覆盖更多等价表述。

按文档维度，IMDB 情感分类报告准确率最高（86%），因为其表格结构清晰、图表类型单一（柱状图、混淆矩阵）；IMF 经济报告准确率最低（56%），主要由于其图表多为折线图趋势读取，对 VLM 的估读精度要求较高，且 8 个 chunk 的索引覆盖相对有限。

五、结论

本文实现并评测了 MultimodalQA——一套面向复杂版面 PDF 文档的多模态 RAG 系统。核心实验结论如下：

1. **多模态架构在视觉题上具有显著优势**：在 100 道需要图表视觉信息的题目上，多模态 RAG 准确率为 65%，显著高于纯文本保守基线（18%）和纯文本开放基线（42%），提升分别为 +47 pp（个百分点）和 +23 pp，McNemar 检验 $\chi^2 = 43.18$, $p < 0.0001$ ，差异高度显著。
2. **优势来源于视觉理解而非基线设计缺陷**：纯文本开放基线（允许推断）的视觉题准确率为 42%，仍显著低于多模态系统（65%），排除了“保守基线因拒答过多而人为拉大差距”的干扰，确认多模态提升真正来自原始图像的视觉语义。
3. **非视觉题上三路无显著差异**：在不需要图表的题目上，三路基线准确率分别为多模态 74%、保守 72%、开放 75%（差距 ≤ 3 pp），McNemar 检验 $p = 0.683$ （不显著），表明系统在文本/表格理解上不因多模态处理引入额外噪声。
4. **困难题多模态优势更突出**：在 22 道 hard 难度题中，保守基线准确率仅 9%，开放基线 36%，多模态 RAG 达 64%，差距随题目难度增大而扩大，说明视觉信息在复杂推理场景下价值更高。
5. **延迟可接受**：多模态模式相比纯文本多出约 1.4 秒/题的图像附加开销（5.0s vs 3.7s），对于离线问答场景代价可接受。纯文本开放基线延迟反而最高（9.8s），推测是“允许推断”的 prompt 使模型生成了更长的思维链。

六、局限性与未来工作

:

1. **英文文档跨语言处理有待改进**：系统的 VLM 摘要和生成 prompt 目前以中文为主，英文文档的图表摘要由 GLM-4.6V 以中文描述，与英文原始内容存在语言不一致；同时评测题目均以中文提问，模型有时混合中英文回答，导致 ANLS 因字符串差异低估了实际回答质量。未来可在 prompt 中根据文档语言自动切换，并扩充英文 gold 答案的等价表述。
2. **检索层缺乏独立评测**：本文的评测采用端到端的准确率指标（最终答案是否正确），未对检索层进行独立的召回率（Recall@K）、精准率（Precision@K）和 MRR 评测。项目已准备了 evaluation/eval_retrieval.py 脚本及 text_keywords 关键词标注，可计算文本 Chunk Recall@K，但图片 Image Recall@K 需逐一标注正确图片文件名，受时间限制未能完成。检索层独立评测能更精准定位“检索失败”与“VLM 理解失败”的边界，是重要的后续工作。
3. **检索参数固定，缺乏自适应策略**：当前 top-k=5、相似度阈值 =0.3 对所有文档和题型统一使用，未根据问题类型（视觉 vs 文本）或文档长度动态调整。自适应检索策略（如对视觉题增大 max_images、对长文档提升 top-k）有望进一步提升召回。

4. **数据集规模与领域多样性受限**：自建数据集共 200 题，hard 难度仅 22 道，英文文档 2 篇，统计结论在部分子集上置信区间仍较宽。未来可引入 DocVQA、ChartQA 等公开数据集扩充至千题以上，覆盖更多文档类型（财报、法律、医疗等）。
5. **VLM 依赖云端 API，延迟受网络影响**：目前摘要生成和答案推理均调用智谱 GLM-4.6V API，单题延迟 5 10 秒，且受网络波动影响较大。未来可本地部署轻量多模态模型（如 Qwen2.5-VL-7B）替代摘要环节，在保持质量的同时显著降低延迟和 API 成本。

参考文献

- [1] Lewis, P., Perez, E., Piktus, A., et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. *NeurIPS*, 2020.
- [2] Asai, A., Wu, Z., Wang, Y., et al. Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection. *ICLR*, 2024.
- [3] Mathew, M., Karatzas, D., Jawahar, C.V. DocVQA: A Dataset for VQA on Document Images. *WACV*, 2021.
- [4] Masry, A., Long, D., Tan, J.T., et al. ChartQA: A Benchmark for Question Answering about Charts with Visual and Logical Reasoning. *ACL Findings*, 2022.
- [5] Faysse, M., Sibille, H., Wu, T., et al. ColPali: Efficient Document Retrieval with Vision Language Models. *ICLR*, 2025.
- [6] Cho, J., Kil, H., Subramani, N., et al. M3DocRAG: Multi-modal Retrieval is What You Need for Multi-page Multi-document Understanding. *arXiv:2411.04952*, 2024.
- [7] Yu, S., Tang, Z., Shen, B., et al. VisRAG: Vision-based Retrieval-augmented Generation on Multi-modality Documents. *ICLR*, 2025.
- [8] Auer, C., Bauer, M., Berrard, N., et al. Docling Technical Report. *arXiv:2408.09869*, 2024.
- [9] Chen, J., Xiao, S., Zhang, P., et al. BGE M3-Embedding: Multi-Lingual, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation. *arXiv:2309.07597*, 2024.