

多模态最终报告 文档理解 + 多模态检索问答系统

小组成员 1: 庄仕豪 学号: 23336355

小组成员 2: 钟晨晖 学号: 23336336

摘要

本文提出并实现了一套面向复杂版面 PDF 文档的多模态检索增强生成 (Multimodal RAG) 系统 MultimodalQA。系统以 IBM Docling 完成 PDF 版面分析与结构化抽取 (文本块 / 表格 Markdown / 图像裁剪), 以智谱 GLM-4.6V 生成图表语义摘要, 以 BAAI/BGE-M3 构建 1024 维稠密向量索引 (ChromaDB 持久化), 并通过 Multi-Vector Retriever 实现“摘要召回、原图回传”的代理检索策略, 最终由 GLM-4.6V 生成带页码与图号引用的多模态答案。

为定量评估系统优势, 本文构建了一个包含 **200 道题目、5 篇文档、4 类领域、3 档难度** 的自建 QA 数据集, 设计三路基线对比: 多模态 RAG (完整系统)、纯文本保守基线 (无图、无证据则拒答)、纯文本开放基线 (无图、允许基于上下文推断), 以 ANLS 与准确率为指标进行评测。实验结果表明, 在必须依赖图表视觉信息的题目上 (100 道), 多模态 RAG 的准确率 (65%) 显著高于纯文本保守基线 (18%) 和纯文本开放基线 (42%), 提升分别为 +47 个百分点 (pp) 和 +23 pp (McNemar 检验 $p < 0.0001$), 而在纯文本题目上三路无显著差异, 验证了多模态架构的必要性与针对性。

系统已实现完整的 Web 前后端 (Vue 3 + FastAPI), 支持 PDF 拖拽上传、实时进度推送 (SSE)、LaTeX 公式渲染与引用溯源。

目录

一、 引言	3
二、 相关工作	3
(一) 检索增强生成 (RAG)	3
(二) 文档视觉理解	3
(三) 多模态 RAG	4
(四) 文档解析工具	4
三、 方法	4
(一) 阶段一: 文档摄取与结构化解析	4
(二) 阶段二: 离线索引构建	5
1. VLM 摘要生成	5
2. BGE-M3 向量化	5

3. 代理召回策略	5
(三) 阶段三: 混合召回	5
(四) 阶段四: 溯源生成	5
四、 系统实现	6
(一) 前后端架构	6
(二) VLM Prompt 设计	6
1. 图表摘要 Prompt (离线索引阶段)	6
2. 答案生成 Prompt (在线推理阶段)	7
五、 实验	7
(一) 实验设置	7
1. 系统配置	7
2. 评测数据集	8
3. 评测指标	8
4. 三路基线设计	9
(二) 实验结果	10
1. 总体性能对比	10
2. 按题型细分	10
3. 按难度分析	11
4. 视觉题 vs 非视觉题	11
5. 统计显著性检验	11
6. 延迟分析	12
7. 可视化分析	12
8. 错误分析	14
六、 结论	15
七、 局限性与未来工作	15

一、引言

随着企业与科研场景中非结构化文档的爆炸式增长，如何从包含复杂排版的 PDF（多栏布局、嵌套表格、统计图表、数学公式）中准确检索并回答自然语言问题，成为文档智能领域的核心挑战。

传统 RAG（Retrieval-Augmented Generation）系统^[1] 在处理纯文本文档时已取得良好效果，但面对图表、混淆矩阵、训练曲线等视觉信息时力不从心——文本化的图说或摘要往往丢失关键的颜色、趋势和精确读数信息，导致模型产生模糊甚至错误的判断。

本文的核心贡献包括：

1. **完整多模态 RAG 管道**：从 PDF 解析、VLM 摘要生成、向量化检索到多模态答案生成的端到端系统，提出”摘要入库、原图回传”的代理召回策略，在不显著增加索引体积的前提下支持图像级问答。
2. **三路消融对比设计**：新增”纯文本开放基线”（无图、允许推断），区分多模态提升来源于”视觉理解”还是”保守基线（无证据则拒答）的过度拒答”，使对比实验更加公平。
3. **多领域双语自建 QA 数据集**：5 篇 PDF 文档，覆盖 4 类领域（个人 ML 实验报告、NLP 学术论文、气候科学报告、宏观经济报告）、200 道题目、3 档难度。其中 2 篇为英文文档（Infini-Attention 论文、IPCC AR6 报告），其余 3 篇为中文文档，所有题目均以中文提问，兼顾了跨语言检索与问答能力的评测。
4. **完整 Web 演示系统**：前后端分离，支持实时进度、前端 LaTeX 渲染、引用溯源弹窗等工程特性。

二、相关工作

（一）检索增强生成（RAG）

Lewis 等人^[1] 提出将稠密检索与序列到序列生成结合的 RAG 框架，将开放域问答的知识存储从参数化记忆转移至可更新的外部文档库，极大提升了模型对长尾知识的覆盖能力。后续工作（如 Self-RAG^[2]、HyDE 等）进一步优化了检索质量与生成的忠实性。

（二）文档视觉理解

DocVQA^[3]、ChartQA^[4] 等数据集揭示了视觉文档理解的独特难点：仅凭 OCR 文本无法回答需要视觉推理的问题（如图表趋势、表格布局）。ColPali^[5] 提出直接以页面图像向量化进行检索，完全绕开文本提取环节；但在精确数值读取上仍有局限。

（三）多模态 RAG

M3DocRAG^[6] 在多文档场景下引入多向量检索与多模态生成；VisRAG^[7] 通过实验证明保留视觉信息对 RAG 的重要性。本文参考上述架构，结合国内可用的 API（智谱 GLM-4.6V）设计了适合中英文混合文档的系统。

（四）文档解析工具

IBM Docling^[8] 提供基于深度学习的 PDF 版面分析，能够高精度分离文本、表格和图像区域，并将表格转为结构化 Markdown，为后续的语义分块和向量化奠定基础。

三、方法

本系统由四个阶段组成，如图 1 所示。




图 1: MultimodalQA 四阶段处理流程

（一）阶段一：文档摄取与结构化解析

输入 PDF 经 IBM Docling（GPU 加速）进行版面分析，输出三类结构化元素：

- 文本块（TEXT）：正文段落、标题、公式，保留标题层级上下文；
- 表格（TABLE）：以 Markdown 格式保留行列结构；
- 图像（FIGURE）：裁剪为独立图片文件，保留页码与标签；
- 页面图（PAGE_IMAGE）：全页渲染，用于引用溯源弹窗。

文本块经过合并小块（min=80 字符）与滑动窗口切分（max=1500, overlap=200）后形成检索单元。

（二）阶段二：离线索引构建

1、VLM 摘要生成

对每个 FIGURE 和 TABLE 元素，调用 GLM-4.6V 生成 100-200 字的语义摘要，作为该视觉元素的文本代理（proxy）存入向量库。摘要描述图表类型、关键数值、趋势与结论，使得纯文本检索模型也能通过语义相似度命中视觉内容。

2、BGE-M3 向量化

使用 BAAI/BGE-M3^[9] 对所有文本块及视觉摘要生成 1024 维稠密向量，以 FP16 精度在 CUDA 设备上完成批量编码（batch=8，max_length=8192）。向量与元数据（页码、类型、标签、图片路径）一同持久化至 ChromaDB。

3、代理召回策略

索引存储的是摘要文本的向量，但元数据中记录了原始图片路径。检索命中摘要后，系统取出 image_path 并将原始图片附加到 VLM Prompt 中，实现”以文本精度检索、以图像质量回答”，兼顾了检索效率（索引体积小）与回答质量（完整视觉信息）。

（三）阶段三：混合召回

用户问题同样经 BGE-M3 编码后，在 ChromaDB 中进行余弦相似度检索（top-k=5，阈值=0.3），返回文本块、表格摘要和图像摘要三类候选。对命中图像摘要的结果，系统进一步加载对应原始图片，组成图文混合的上下文包（context pack）。

（四）阶段四：溯源生成

系统支持三种生成模式：

- **auto**（多模态）：有图像时将原图与文本上下文一并传入 GLM-4.6V，启用多模态推理；
- **grounded**（诚实基线）：仅使用文本上下文，无足够证据时明确拒答；
- **open**（公平基线）：仅使用文本上下文，允许基于间接上下文进行合理推断。

GLM-4.6V 按 system prompt 要求在回答末尾附加结构化引用标签：

```
<citation page="5" type="figure" label="Figure 1"/>
```

前端解析该标签，渲染为可点击的”第 5 页”按钮，点击弹窗显示对应页面原图。

四、系统实现

（一）前后端架构

系统采用前后端分离架构：后端基于 FastAPI 提供 REST API 与 SSE（Server-Sent Events）流式推送，前端基于 Vue 3 + Vite 构建，通过 HTTP/SSE 与后端通信。

后端（backend/）共 7 个 API 端点，核心流程如下：

- POST /api/upload: 接收 PDF 文件，分配 task_id，异步触发四阶段处理管道；
- GET /api/upload/{task_id}/progress: SSE 流，实时推送每个阶段的进度百分比与阶段名称；
- POST /api/chat: 接收用户问题与文档 ID，调用检索-生成管道，返回答案、引用列表与（可选）图片。

处理管道运行在后台线程池中，通过 `asyncio.Queue` 向 SSE 端点传递进度事件，保证主线程不阻塞。ChromaDB 的向量索引持久化到磁盘（backend/chroma_data/），重启后端无需重建。

前端（frontend/）关键组件包括：

- Sidebar.vue: PDF 拖拽上传与文档列表管理，支持点选切换当前文档；
- UploadProgress.vue: 实时进度弹窗，订阅 SSE 流，按阶段显示中文名称与耗时；
- ChatPanel.vue + MessageBubble.vue: 图文混合对话框，通过 KaTeX 渲染 LaTeX 公式，引用标签渲染为可点击按钮；
- AppHeader.vue: 顶部 RAG 模式切换开关（Multimodal / Text-only），通过 props 透传至 API 调用层。

（二）VLM Prompt 设计

系统在三个环节调用 GLM-4.6V，每个环节的 prompt 设计如下。

1、图表摘要 Prompt（离线索引阶段）

对图像元素，prompt 要求 VLM 描述图表类型、关键数值与趋势；对表格元素，以 Markdown 格式传入原始表格，要求 VLM 概括字段含义与核心对比：

```
1 # 图像摘要 prompt (简化展示)
2 "你是专业文档分析助手。仔细观察这张图片，生成简洁但信息丰富的文本描述。
3 要求：
4 1. 描述图表类型（折线图/柱状图/散点图等）
5 2. 概括主要趋势、关键数值或核心结论
6 3. 提及图例/坐标轴的关键信息
7 4. 用中文回答，100-200字以内"
```

摘要以纯文本形式存入 ChromaDB，同时在元数据中记录原始图片路径，支持后续代理召回。

2、答案生成 Prompt（在线推理阶段）

多模态模式下，将检索到的文本上下文与原始图片一并构造 content array 传入 GLM-4.6V；纯文本模式仅传文本。核心 system prompt 如下：

```
1 SYSTEM_PROMPT = """你是专业的文档问答助手。根据提供的文档内容
2 （包括文本片段、表格和图片），准确回答用户的问题。
3 严格要求：
4 1. 只根据提供的文档内容回答，不要编造信息
5 2. 回答结束后必须标注引用来源：
6   <citation page="页码" type="类型" label="标签"/>
7 3. 如果文档内容无法回答，明确说明"根据提供的文档内容无法回答"
8 4. 回答要简洁准确，突出关键数据和结论"""
9
10 # 纯文本开放基线的 prompt 则允许推断：
11 OPEN_SYSTEM_PROMPT = """...优先根据文档内容直接回答。
12 若文档没有直接信息，可基于文档中的相关上下文进行合理推断，
13 并在回答末尾注明"（推断）"..."""
```

两个 prompt 的核心差异在于对”无证据时”的处理策略：保守 prompt 要求明确拒答，开放 prompt 允许基于间接证据推断。这正是三路消融实验中”保守基线”与”开放基线”行为差异的根本来源。

五、实验

（一）实验设置

1、系统配置

表 1: 系统核心配置

组件	配置
文档解析	IBM Docling 2.95（GPU 加速，CUDA 12.4）
嵌入模型	BAAI/BGE-M3，1024 维，FP16，CUDA
向量库	ChromaDB（余弦相似度，持久化）
VLM	智谱 GLM-4.6V（max_tokens=4096，temperature=0.1）
检索参数	top-k=5，score_threshold=0.3，max_images=3
运行环境	Windows 11，RTX 4070/4060 Laptop GPU（8GB），Python 3.10

2、评测数据集

本文构建了一个多领域双语自建 QA 数据集（表 2），共 200 道题目，涵盖 5 篇 PDF（3 篇中文文档、2 篇英文文档）、4 类领域、3 种题型、3 档难度。所有题目均以中文提问，兼顾了中英双语文档的跨语言检索与问答。

题型上，本文将题目分为两大类：

- **视觉题**（requires_visual=true，共 100 道）：必须依赖图表的视觉信息才能正确回答，包含两种子类型：（a）**仅靠图片才能回答**——如混淆矩阵单元格读数、训练曲线趋势判断，文本摘要中不包含这些数值；（b）**图片有明显帮助**——如颜色读取、图表比较、多图对比，文字描述存在但远不如直接看图准确。
- **非视觉题**（共 100 道）：仅凭文本或表格内容即可作答，无需图像，如精确数值读取、段落理解等。

视觉题与非视觉题的划分是本实验消融设计的核心依据：在非视觉题上，三种基线模式理论上能力相当；在视觉题上，多模态系统因能直接读取原始图片而具有明显优势。

表 2: 评测数据集构成

文档	领域	题数	视觉题
K-Means/GMM 实验报告	ML 实验	40	17
IMDB 情感分类报告	ML 实验	40	19
Infini-Attention 论文（arXiv）	CS / NLP	32	12
IPCC AR6 综合报告摘要	气候/环境	44	20
IMF 战略经济前景报告	宏观经济	34	22
合计	5 篇（4 类）	200	100（50%）

题型分布：figure（图表类）100 道，table（表格数值）55 道，text（文本理解）45 道。难度分布：easy 101 道，medium 77 道，hard 22 道。

3、评测指标

本文使用两个互补指标：

- **ANLS**（Average Normalized Levenshtein Similarity，平均归一化编辑距离相似度）
ANLS 是 DocVQA^[3] 提出的文档问答标准指标，专为应对“回答措辞与标准答案不同但语义正确”的场景设计。计算分三步：

1. **NLS**（单题单答案相似度）：

$$\text{NLS}(\hat{a}, a) = 1 - \frac{\text{EditDistance}(\hat{a}, a)}{\max(|\hat{a}|, |a|)}$$

完全一致得 1.0，完全不同得 0.0。

2. **阈值截断**（ $\tau = 0.5$ ）：若一道题有多个等价标准答案，取其中与预测相似度最高的 NLS；若该最大 NLS < 0.5，则本题得分归零（表示“差距过大，视为答错”）；否则保留 NLS

值。

3. ANLS = 全部题目得分的算术平均值。

扩展处理：标准 NLS 仅做字符级编辑距离，对文档 QA 中常见的以下情形会误判为“错”，因此本文在计算 NLS 前额外增加三条预处理规则（按优先级顺序）：

1. 子串包含：若标准答案作为子串出现在模型回答中，直接给满分。

例：标准答案为 0.5937，模型回答“Random 初始化的测试集准确率为 0.5937”，编辑距离很大，但答案已包含在内，判为正确。

2. 数值格式归一化：百分数与小数视为等价。

例：标准答案为 59.37%，模型回答 0.5937，自动转换后判为正确。

3. 有序比较：标准答案形如 A > B 时，只要模型回答中 A、B 按顺序出现即判为正确。

例：标准答案为 Full > Spherical，模型答“Full 协方差性能最优，其次是 Spherical”，判为正确。

- **准确率 (Accuracy)：**以单题 $NLS \geq 0.5$ 作为“答对”的判定标准，统计答对题数占总题数的比例。相比 ANLS 均值，准确率更直观，便于按题型、难度、视觉/非视觉等维度进行分组对比。

4、三路基线设计

表 3: 三路基线对比设计

模式	检索内容	角色
多模态 RAG	文本 + 表格摘要 + 原始图片	完整系统
纯文本保守基线	文本 + 表格摘要，无图	无视觉证据则明确拒答
纯文本开放基线	文本 + 表格摘要，无图	允许基于上下文合理推断

新增纯文本开放基线的动机：若多模态系统优势仅来自保守基线的“过度拒答”而非真实视觉理解，则开放基线的分数应接近多模态系统。若开放基线仍显著低于多模态系统，则可确认优势来自视觉信息。

（二）实验结果

1、总体性能对比

表 4: 三路基线总体性能对比（200 题）

模式	ANLS	Accuracy 准确率
多模态 RAG	0.6950	69.50%
纯文本保守基线	0.4500	45.00%
纯文本开放基线	0.5850	58.50%
多模态 vs 保守基线（提升）	+0.2450	+24.5 pp
多模态 vs 开放基线（提升）	+0.1100	+11.0 pp

多模态 RAG 在整体准确率上达到 69.5%，比保守基线（45.0%）高出 24.5 个百分点，比允许推断的开放基线（58.5%）高出 11.0 个百分点。开放基线相比保守基线提升了 13.5 pp，说明在没有图片的情况下允许模型推断确实有助于提高准确率，但仍不及多模态系统，证明差距的主要来源是视觉信息而非基线设计缺陷。

2、按题型细分

表 5: 按题型分类的准确率对比

题型	数量	多模态	纯文本保守	纯文本开放
figure（视觉图表）	100	65%	18%	42%
table（表格数值）	55	73%	71%	75%
text（文本理解）	45	76%	73%	76%

题型分析揭示了三个规律：（1）**figure 类差距最显著**：多模态（65%）vs 保守基线（18%），差距达 47 pp。保守基线在图表题上的 18% 准确率中，绝大多数（85%）来自拒答，说明纯文本系统几乎无法回答需要读图的问题。（2）**table 和 text 类三路基本持平**：多模态与两个纯文本基线的差距均在 5 pp 以内，说明多模态架构在处理结构化文本和表格时不引入额外噪声，与纯文本系统等效。值得注意的是开放基线在 table 题上（75%）略高于多模态（73%），这是因为表格以 Markdown 文本形式存入索引，纯文本系统也能直接读取精确数值，而多模态系统有时会将图片和表格混淆召回，引入轻微干扰。（3）**结论**：多模态架构的优势高度集中于视觉信息密集的题目，对纯文本推理能力无负面影响，体现了“按需使用视觉”的设计合理性。

3、按难度分析

表 6: 按难度分类的准确率对比

难度	数量	多模态	纯文本保守	纯文本开放
easy (简单)	101	76%	64%	70%
medium (中等)	77	62%	30%	49%
hard (困难)	22	64%	9%	36%

难度梯度分析表明，多模态优势随题目难度增大而扩大：easy 题多模态领先保守基线 12 pp，medium 题扩大至 32 pp，hard 题达到 55 pp。hard 题中保守基线准确率仅 9%（22 题中答对 2 题），说明这类需要跨图比较或多步推理的题目对纯文本系统几乎无解，而多模态系统能借助原始图像完成更复杂的视觉推理，准确率维持在 64%。多模态系统自身在 medium 题（62%）略低于 easy 题（76%），主要因为 medium 题更多涉及趋势判断和区域比较，对 VLM 的图表理解能力要求更高。

4、视觉题 vs 非视觉题

表 7: 视觉题与非视觉题准确率对比

子集	数量	多模态	纯文本保守	纯文本开放
视觉题	100	65%	18%	42%
非视觉题	100	74%	72%	75%

视觉/非视觉对比是本实验设计的核心消融维度。在非视觉题上，三路基线差距极小（多模态 74%、保守 72%、开放 75%），McNemar 检验 $p = 0.683$ ，差异统计上不显著，证明多模态系统在不需要图像的题目上与纯文本系统完全等效——即视觉模块不会干扰文本推理。在视觉题上，多模态（65%）vs 保守基线（18%）差距为 47 pp，McNemar 检验 $\chi^2 = 43.18$ ， $p < 0.0001$ ，高度显著。两个子集结论形成鲜明对比，精确定位了多模态架构发挥作用的边界：凡是需要图表信息的题目，视觉模块带来显著提升；凡是不需要图表的题目，视觉模块不产生额外代价。

5、统计显著性检验

对多模态 RAG 与纯文本保守基线在相同题目上的配对二分类结果，应用 McNemar 检验（适用于配对样本的 2×2 列联表）。

检验统计量：

$$\chi^2 = \frac{(b - c)^2}{b + c} \quad (1)$$

其中 b 为”多模态对、纯文本错”的题数， c 为”多模态错、纯文本对”的题数。

表 8: McNemar 检验结果（多模态 vs 纯文本保守基线）

子集	b (多模态对、保守错)	c (多模态错、保守对)	χ^2	p
全部 (n=200)	52	3	41.89	< 0.0001 (显著)
视觉题 (n=100)	48	1	43.18	< 0.0001 (显著)
非视觉题 (n=100)	4	2	0.17	0.683 (不显著)

在视觉题子集中, $b = 48$ (多模态答对但保守基线答错) 远大于 $c = 1$ (反之), 不对称性极强, $\chi^2 = 43.18$, $p < 0.0001$, 差异高度显著。在非视觉题子集中, $b = 4$, $c = 2$, $p = 0.683$, 不显著, 与上节结论吻合: 两个系统在不依赖图像的题目的能力相当。这一检验排除了”随机波动”对结论的威胁, 证明多模态系统的优势具有统计可信性。

6、延迟分析

表 9: 平均每题推理延迟

模式	平均延迟 (秒/题)
多模态 RAG	5.0
纯文本保守基线	3.7
纯文本开放基线	9.8
图像附加开销 (多模态 - 保守基线)	+1.4
平均每题图片数	1.42

多模态 RAG 平均每题耗时 5.0 秒, 相比保守基线 (3.7 秒) 仅多出 1.4 秒, 折算为每张图约 1.0 秒的额外开销 (平均 1.42 张/题), 代价极小。值得注意的是开放基线 (9.8 秒) 延迟反而最高, 接近多模态的两倍, 原因在于”允许推断”的 prompt 引导模型生成更长的推理链, 说明延迟瓶颈在于 LLM 生成长度而非图像传输。综合来看, 多模态模式在仅增加 28% 延迟 (1.4/5.0) 的前提下, 将视觉题准确率从 18% 提升至 65%, 性价比显著。

7、可视化分析

图 2 (三路基线按题型准确率对比): 柱状图从左到右依次为 figure、table、text 三类题型, 三组柱分别对应三路基线。最显著的特征是 figure 类中三条柱高度的极端不对称: 多模态柱 (65%) 远高于保守柱 (18%), 而 table 和 text 两类中三条柱几乎等高。这一视觉模式直接支持了核心论点: 多模态优势高度集中于图表类题目, 对文本/表格类题目不产生影响。值得关注的是开放基线在 figure 类的 42%——它显著高于保守基线 (18%), 说明允许推断确实有帮助, 但与多模态的 65% 仍有 23 pp 的差距, 证明这部分差距无法通过”放开推断限制”来弥合, 必须依赖真实的视觉信息。




图 2: 三路基线按题型准确率对比。figure 类差距达 47 pp, table/text 类三路基本持平; 开放基线在 figure 类 (42%) 介于两者之间, 说明多模态优势并非全来自”拒答偏差”。

图 3 (视觉题 vs 非视觉题三路准确率对比): 左侧视觉题组中, 三路基线的准确率形成明显梯度 (65% / 42% / 18%), 与 figure 类分析结论一致。右侧非视觉题组中, 三条柱高度几乎相同 (74% / 75% / 72%), 差距不超过 3 pp, 统计上不显著 (McNemar $p = 0.683$)。两组之间的对比揭示了一个重要性质: 视觉模块的引入是”加法”而非”乘法”——它只在需要图像的题目上贡献增量, 不干扰不需要图像的题目。这一性质使系统在混合文档场景下具有良好的鲁棒性。




图 3: 视觉题 (左) vs 非视觉题 (右) 三路准确率对比。视觉题组差距高度显著 ($p < 0.0001$); 非视觉题组三路等效 ($p = 0.683$), 印证了视觉模块”按需启用、不引入噪声”的设计目标。

图 4 (每道题 ANLS 得分热图): 热图的三行分别对应多模态 RAG、纯文本保守和纯文本开放, 列对应 200 道题 (按文档顺序排列)。从中可以观察到几个规律: (1) 保守基线行在约 q36-q105 区间 (对应 figure 类集中题目) 出现大量深色 (低分) 区域, 而多模态行同一区域颜色明显更浅, 两行的色差最为突出; (2) 多模态行自身也存在若干深色格子, 主要集中在 hard 难度题目 (q18、q20 等), 对应前述 VLM 视觉误判的失败模式; (3) 三行在表格类和文本类题目 (约 q100-

q200) 区域颜色分布基本一致，保守基线在此区间的深色格子大幅减少，与”非视觉题三路等效”的量化结论吻合。热图整体呈现的色差模式，是对量化指标的直观佐证。




图 4: 每道题 ANLS 得分热图（行：三种模式，列：题号）。保守基线行在 figure 类题目区间（约 q1-q100）出现大量深色，多模态行在同区间颜色显著更浅；三行在非视觉类题目区间颜色趋于一致。

8、错误分析

多模态 RAG 共答错 61 道题（准确率 69.5%），对失败案例按题型和原因进行分类，结果如表 10 和图 5 所示。

表 10: 多模态 RAG 失败案例分布

类别	失败数	占全部失败	该类型失败率
figure 题失败	35	57%	35%（35/100）
table 题失败	15	25%	27%（15/55）
text 题失败	11	18%	24%（11/45）
figure 细分：			
图像未召回（检索失败）	5	8%	14%（5/35 figure 失败）
图像已召回但仍答错（VLM 误判）	30	49%	86%（30/35 figure 失败）




图 5: 纯文本保守基线在视觉题上的失败原因分布。82 道答错题中 85% 为拒答，15% 为答错。

- 综合分析，多模态 RAG 的失败案例可归纳为以下四类：
- 1. **VLM 视觉理解误判（最主要，约 49% 的失败）**：图像已被正确召回并发送给 GLM-4.6V，但 VLM 对图表的读数或趋势判断出现偏差。典型场景包括：折线图趋势方向判断错误（混淆”上升”与”下降”）、柱状图数值读取精度不足（对近似值的估读存在偏差）、多子图对比时注意力分散（如 4 张混淆矩阵需同时比较）。这是当前系统最主要的失败来源，根本限制在于 VLM 的图表理解能力上限。
 - 2. **图像检索失败（约 8% 的失败，即 5 道）**：相关图表未被 top-5 召回，系统在没有视觉信息的情况下降级为纯文本推理，导致答错。主要发生在长文档（IPCC 报告、英文论文）中图表

标题与问题措辞差异较大的情况下。

3. **跨语言答案匹配偏差 (约 8%)**: 2 篇英文文档的题目以中文提问, 模型有时混合中英文回答, 导致即使语义正确、ANLS 也因字符串差异被低估而判为答错。例如模型答“K-Means++”而 gold 为“KMeans++”, 编辑距离非零但语义等价。
4. **标准答案粒度不匹配 (约 18% 的 table/text 失败)**: 对于需要回答区间或趋势描述的题目 (如“约 50 60 cm”), 模型给出的具体数值 (“约 75cm”) 与标准答案粒度不同, ANLS 判为答错但实际语义可能是合理的。这类问题的改进方向是完善 gold 答案覆盖更多等价表述。

按文档维度, IMDB 情感分类报告准确率最高 (86%), 因为其表格结构清晰、图表类型单一 (柱状图、混淆矩阵); IMF 经济报告准确率最低 (56%), 主要由于其图表多为折线图趋势读取, 对 VLM 的估读精度要求较高, 且 8 个 chunk 的索引覆盖相对有限。

六、结论

本文实现并评测了 MultimodalQA——一套面向复杂版面 PDF 文档的多模态 RAG 系统。核心实验结论如下:

1. **多模态架构在视觉题上具有显著优势**: 在 100 道需要图表视觉信息的题目上, 多模态 RAG 准确率为 65%, 显著高于纯文本保守基线 (18%) 和纯文本开放基线 (42%), 提升分别为 +47 pp (个百分点) 和 +23 pp, McNemar 检验 $\chi^2 = 43.18$, $p < 0.0001$, 差异高度显著。
2. **优势来源于视觉理解而非基线设计缺陷**: 纯文本开放基线 (允许推断) 的视觉题准确率为 42%, 仍显著低于多模态系统 (65%), 排除了“保守基线因拒答过多而人为拉大差距”的干扰, 确认多模态提升真正来自原始图像的视觉语义。
3. **非视觉题上三路无显著差异**: 在不需要图表的题目上, 三路基线准确率分别为多模态 74%、保守 72%、开放 75% (差距 ≤ 3 pp), McNemar 检验 $p = 0.683$ (不显著), 表明系统在文本/表格理解上不因多模态处理引入额外噪声。
4. **困难题多模态优势更突出**: 在 22 道 hard 难度题中, 保守基线准确率仅 9%, 开放基线 36%, 多模态 RAG 达 64%, 差距随题目难度增大而扩大, 说明视觉信息在复杂推理场景下价值更高。
5. **延迟可接受**: 多模态模式相比纯文本多出约 1.4 秒/题的图像附加开销 (5.0s vs 3.7s), 对于离线问答场景代价可接受。纯文本开放基线延迟反而最高 (9.8s), 推测是“允许推断”的 prompt 使模型生成了更长的思维链。

七、局限性与未来工作

1. **英文文档跨语言处理有待改进**: 系统的 VLM 摘要和生成 prompt 目前以中文为主, 英文文档的图表摘要由 GLM-4.6V 以中文描述, 与英文原始内容存在语言不一致; 同时评测题目均以

中文提问，模型有时混合中英文回答，导致 ANLS 因字符串差异低估了实际回答质量。未来可在 prompt 中根据文档语言自动切换，并扩充英文 gold 答案的等价表述。

2. **检索层缺乏独立评测：**本文的评测采用端到端的准确率指标（最终答案是否正确），未对检索层进行独立的召回率（Recall@K）、精准率（Precision@K）和 MRR 评测。项目已准备了 evaluation/eval_retrieval.py 脚本及 text_keywords 关键词标注，可计算文本 Chunk Recall@K，但图片 Image Recall@K 需逐一标注正确图片文件名，受时间限制未能完成。检索层独立评测能更精准定位“检索失败”与“VLM 理解失败”的边界，是重要的后续工作。
3. **检索参数固定，缺乏自适应策略：**当前 top-k=5、相似度阈值 =0.3 对所有文档和题型统一使用，未根据问题类型（视觉 vs 文本）或文档长度动态调整。自适应检索策略（如对视觉题增大 max_images、对长文档提升 top-k）有望进一步提升召回。
4. **数据集规模与领域多样性受限：**自建数据集共 200 题，hard 难度仅 22 道，英文文档 2 篇，统计结论在部分子集上置信区间仍较宽。未来可引入 DocVQA、ChartQA 等公开数据集扩充至千题以上，覆盖更多文档类型（财报、法律、医疗等）。
5. **VLM 依赖云端 API，延迟受网络影响：**目前摘要生成和答案推理均调用智谱 GLM-4.6V API，单题延迟 5 10 秒，且受网络波动影响较大。未来可本地部署轻量多模态模型（如 Qwen2.5-VL-7B）替代摘要环节，在保持质量的同时显著降低延迟和 API 成本。

参考文献

- [1] Lewis, P., Perez, E., Piktus, A., et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. *NeurIPS*, 2020.
- [2] Asai, A., Wu, Z., Wang, Y., et al. Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection. *ICLR*, 2024.
- [3] Mathew, M., Karatzas, D., Jawahar, C.V. DocVQA: A Dataset for VQA on Document Images. *WACV*, 2021.
- [4] Masry, A., Long, D., Tan, J.T., et al. ChartQA: A Benchmark for Question Answering about Charts with Visual and Logical Reasoning. *ACL Findings*, 2022.
- [5] Faysse, M., Sibille, H., Wu, T., et al. ColPali: Efficient Document Retrieval with Vision Language Models. *ICLR*, 2025.
- [6] Cho, J., Kil, H., Subramani, N., et al. M3DocRAG: Multi-modal Retrieval is What You Need for Multi-page Multi-document Understanding. *arXiv:2411.04952*, 2024.
- [7] Yu, S., Tang, Z., Shen, B., et al. VisRAG: Vision-based Retrieval-augmented Generation on Multi-modality Documents. *ICLR*, 2025.

- [8] Auer, C., Bauer, M., Berrard, N., et al. Docling Technical Report. *arXiv:2408.09869*, 2024.
- [9] Chen, J., Xiao, S., Zhang, P., et al. BGE M3-Embedding: Multi-Lingual, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation. *arXiv:2309.07597*, 2024.